Processamento Base de Dados de Crédito

Luciano Teixeira

27 de outubro de 2018

Processamento Base de Dados de Crédito

O propósio deste relatorio é analisar ma base de dados de crédito com 2000 registros, identificando qual dos clientes, ao solicitar um impréstimo, possui a maior chance de efetuar o pagamento ou não deste impréstimo, levando em consideração:

1-Idade

2-Renda

3-Historico Financeiro

Foram, uilizados três algoritmos de Machine Learning para avaliar a mesma base:

1-Naive Bayes

2-Regressão Logística

3-Árvore de Decisão

Para estes algorítmos, foram adotas alguns procedimentos de ajustes, "ETL", para eventuais correções, alterações, seja por conta de categorias de variaveis, seja por erro oriundos de intervenções manuais

1- Importação da base de dados, com o propósito de ler o arquivo csv para sua classificação;

2- Eliminação da coluna de clientid, pois não há propósito de categoria ou calssificação desta coluna;

3- Substituição de valores negativos pela média de idade positiva da base, a fim de minimizar a interferencia nos dados;

4- Substituição de vaores nulos "NA" pela média da idade possitiva, a fim de minimizar a interferencia nos dados;

5- Efetuado o nivelamento da escala, por exemplo, entre a idade e a renda, pois a valor da renda em escala comparado à idade, é muito maior, sendo assim, a aprendizagem não é eficiente;

6- O Encode da Classe ou transformação do atributos categoricos em discretos, é fundamental pois diversas bibliotecas não aceitam como entrada, atributos caegóricos.

7- Divisão da base em dados de treinamento e dados de teste.

Naive Bayes - Aprendizagem Baysiana

Importando a Base de Dados

```
base = read.csv('BaseCredito.csv')
```

Eliminando coluna clientid

```
base$clientid = NULL
```

Preencher os valores negativos com a média dos valores positivos da coluna Age

```
base$age = ifelse(base$age < 0, 40.92, base$age)
```

Preencher os valores nulos

```
base$age = ifelse(is.na(base$age), mean(base$age, na.rm = TRUE), base$age)
```

Executando o Escalonamento, transformando os atributos numéricos na mesma escala

```
base[, 1:3] = scale(base[, 1:3])
```

Encode da classe

```
base$default = factor(base$default, levels = c(0,1))
```

Executando a divisão da base de dados entre treinamento e teste

```
library(caTools)
set.seed(1)
divisao = sample.split(base$income, SplitRatio = 0.75)
base_treinamento = subset(base, divisao == TRUE)
base_teste = subset(base, divisao == FALSE)
```

Executando a primeira avaliação atraves da criação do classificador

```
library(e1071)
classificador = naiveBayes(x = base_treinamento[-4], y = base_treinamento$default)
print(classificador)
```

```
##
## Naive Bayes Classifier for Discrete Predictors
##
## Call:
## naiveBayes.default(x = base_treinamento[-4], y = base_treinamento$default)
##
## A-priori probabilities:
## base_treinamento$default
##    0    1
## 0.86 0.14
##
## Conditional probabilities:
##                          income
## base_treinamento$default        [,1]      [,2]
##                        0  0.02708989 1.0056153
##                        1 -0.01497691 0.9986076
##
##                          age
## base_treinamento$default       [,1]      [,2]
##                        0  0.1818852 0.9602073
##                        1 -1.0899467 0.3471400
##
##                          loan
## base_treinamento$default       [,1]      [,2]
##                        0 -0.1331196 0.9492901
##                        1  0.9029659 0.8384080
```

```
previsoes = predict(classificador, newdata = base_teste[-4])
```

Executando a verificação do índice de acertos

```
matriz_confusao = table(base_teste[, 4], previsoes)
print(matriz_confusao)
```

```
##    previsoes
##       0   1
##   0 421   6
##   1  26  47
```

```
library(caret)
```

```
## Loading required package: lattice
```

```
## Loading required package: ggplot2
```

```
confusao_nb = confusionMatrix(matriz_confusao)
confusionMatrix(matriz_confusao)
```

```
## Confusion Matrix and Statistics
##
##    previsoes
##       0   1
##   0 421   6
##   1  26  47
##
##                Accuracy : 0.936
##                  95% CI : (0.9108, 0.9558)
##     No Information Rate : 0.894
##     P-Value [Acc > NIR] : 0.0007810
##
##                   Kappa : 0.7105
##  Mcnemar's Test P-Value : 0.0007829
##
##             Sensitivity : 0.9418
##             Specificity : 0.8868
##          Pos Pred Value : 0.9859
##          Neg Pred Value : 0.6438
##              Prevalence : 0.8940
##          Detection Rate : 0.8420
##    Detection Prevalence : 0.8540
##       Balanced Accuracy : 0.9143
##
##        'Positive' Class : 0
##
```

ZeroR

```
table(base_teste$default)
```

```
##
##   0   1
## 427  73
```

Regressão Logística

Importando a Base de Dados

```
base = read.csv('BaseCredito.csv')
```

Eliminando coluna clientid

```
base$clientid = NULL
```

Preencher os valores negativos com a média dos valores positivos da coluna Age

```
base$age = ifelse(base$age < 0, 40.92, base$age)
```

Preencher os valores nulos

```
base$age = ifelse(is.na(base$age), mean(base$age, na.rm = TRUE), base$age)
```

Executando o Escalonamento, transformando os atributos numéricos na mesma escala

```
base[, 1:3] = scale(base[, 1:3])
```

Executando a divisão da base de dados entre treinamento e teste

```
library(caTools)
set.seed(1)
divisao = sample.split(base$income, SplitRatio = 0.75)
base_treinamento = subset(base, divisao == TRUE)
base_teste = subset(base, divisao == FALSE)
```

Executando a primeira avaliação atraves da criação do classificador

```
classificador = glm(formula = default ~ ., family = binomial, data = base_treinamento)
probabilidades = predict(classificador, type = 'response', newdata = base_teste[-4])
previsoes = ifelse(probabilidades > 0.5, 1, 0)
```

Executando a verificação do índice de acertos

```
matriz_confusao = table(base_teste[, 4], previsoes)
print(matriz_confusao)
```

```
##    previsoes
##       0   1
##   0 418   9
##   1  16  57
```

```
library(caret)
confusao_rl = confusionMatrix(matriz_confusao)
confusionMatrix(matriz_confusao)
```

```
## Confusion Matrix and Statistics
##
##    previsoes
##       0   1
##   0 418   9
##   1  16  57
##
##                Accuracy : 0.95
##                  95% CI : (0.9271, 0.9674)
##     No Information Rate : 0.868
##     P-Value [Acc > NIR] : 1.021e-09
```

```
##
##                   Kappa : 0.7912
##  Mcnemar's Test P-Value : 0.2301
##
##             Sensitivity : 0.9631
##             Specificity : 0.8636
##          Pos Pred Value : 0.9789
##          Neg Pred Value : 0.7808
##              Prevalence : 0.8680
##          Detection Rate : 0.8360
##    Detection Prevalence : 0.8540
##       Balanced Accuracy : 0.9134
##
##        'Positive' Class : 0
##
```

ZeroR

```
table(base_teste$default)
```

```
##
##   0   1
## 427  73
```

Árvore de Decisão

Importando a Base de Dados

```
base = read.csv('BaseCredito.csv')
```

Eliminando coluna clientid

```
base$clientid = NULL
```

Preencher os valores negativos com a média dos valores positivos da coluna Age

```
base$age = ifelse(base$age < 0, 40.92, base$age)
```

Preencher os valores nulos

```
base$age = ifelse(is.na(base$age), mean(base$age, na.rm = TRUE), base$age)
```

Executando o Escalonamento, transformando os atributos numéricos na mesma escala

```
base[, 1:3] = scale(base[, 1:3])
```

Encode da classe

```r
base$default = factor(base$default, levels = c(0,1))
```

Executando a divisão da base de dados entre treinamento e teste

```r
library(caTools)
set.seed(1)
divisao = sample.split(base$income, SplitRatio = 0.75)
base_treinamento = subset(base, divisao == TRUE)
base_teste = subset(base, divisao == FALSE)
```

Executando a primeira avaliação atraves da criação do classificador

```r
library(rpart)
classificador = rpart(formula = default ~ ., data = base_treinamento)
print(classificador)
```

```
## n= 1500
##
## node), split, n, loss, yval, (yprob)
##       * denotes terminal node
##
##  1) root 1500 210 0 (0.86000000 0.14000000)
##    2) age>=-0.4569664 946   0 0 (1.00000000 0.00000000) *
##    3) age< -0.4569664 554 210 0 (0.62093863 0.37906137)
##      6) loan< 0.3190762 356  52 0 (0.85393258 0.14606742)
##       12) income>=-0.953323 240   5 0 (0.97916667 0.02083333) *
##       13) income< -0.953323 116  47 0 (0.59482759 0.40517241)
##         26) loan< -0.5571763 69   3 0 (0.95652174 0.04347826) *
##         27) loan>=-0.5571763 47   3 1 (0.06382979 0.93617021) *
##      7) loan>=0.3190762 198  40 1 (0.20202020 0.79797980)
##       14) loan< 0.9402764 95  37 1 (0.38947368 0.61052632)
##         28) income>=0.2655176 42   5 0 (0.88095238 0.11904762) *
##         29) income< 0.2655176 53   0 1 (0.00000000 1.00000000) *
##       15) loan>=0.9402764 103   3 1 (0.02912621 0.97087379) *
```

```r
library(rpart.plot)
rpart.plot(classificador)
```

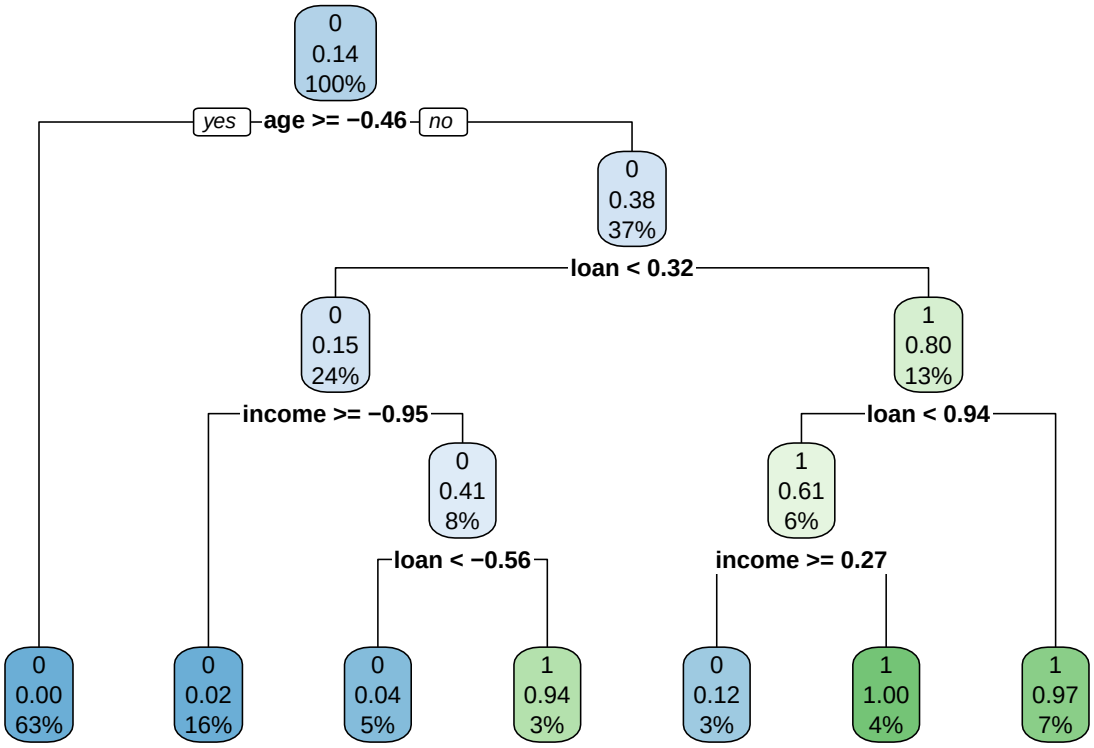

Executando a verificação do índice de acertos

```
previsoes = predict(classificador, newdata = base_teste[-4], type = 'class')
matriz_confusao = table(base_teste[, 4], previsoes)
print(matriz_confusao)
```

```
##    previsoes
##       0   1
##   0 420   7
##   1  11  62
```

```
library(caret)
confusao_ad = confusionMatrix(matriz_confusao)
confusionMatrix(matriz_confusao)
```

```
## Confusion Matrix and Statistics
##
##    previsoes
##       0   1
##   0 420   7
##   1  11  62
##
##                Accuracy : 0.964
##                  95% CI : (0.9437, 0.9785)
##     No Information Rate : 0.862
##     P-Value [Acc > NIR] : 1.534e-14
```

```
##
##                   Kappa : 0.8523
##  Mcnemar's Test P-Value : 0.4795
##
##             Sensitivity : 0.9745
##             Specificity : 0.8986
##          Pos Pred Value : 0.9836
##          Neg Pred Value : 0.8493
##              Prevalence : 0.8620
##          Detection Rate : 0.8400
##    Detection Prevalence : 0.8540
##       Balanced Accuracy : 0.9365
##
##        'Positive' Class : 0
##
```

Como algoritmo mais eifciente temos o Regressão Logística, que pode ser constatado abaixo de acordo como a conerencia da matriz de confusão.

Naive Bayes - Aprendizagem Baysiana

```
print(confusao_nb)
```

```
## Confusion Matrix and Statistics
##
##    previsoes
##       0   1
##   0 421   6
##   1  26  47
##
##                Accuracy : 0.936
##                  95% CI : (0.9108, 0.9558)
##     No Information Rate : 0.894
##     P-Value [Acc > NIR] : 0.0007810
##
##                   Kappa : 0.7105
##  Mcnemar's Test P-Value : 0.0007829
##
##             Sensitivity : 0.9418
##             Specificity : 0.8868
##          Pos Pred Value : 0.9859
##          Neg Pred Value : 0.6438
##              Prevalence : 0.8940
##          Detection Rate : 0.8420
##    Detection Prevalence : 0.8540
##       Balanced Accuracy : 0.9143
##
##        'Positive' Class : 0
##
```

Regressão Logística

```
print(confusao_rl)
```

```
## Confusion Matrix and Statistics
##
##    previsoes
##       0   1
##   0 418   9
##   1  16  57
##
##                Accuracy : 0.95
##                  95% CI : (0.9271, 0.9674)
##     No Information Rate : 0.868
##     P-Value [Acc > NIR] : 1.021e-09
##
##                   Kappa : 0.7912
##  Mcnemar's Test P-Value : 0.2301
##
##             Sensitivity : 0.9631
##             Specificity : 0.8636
##          Pos Pred Value : 0.9789
##          Neg Pred Value : 0.7808
##              Prevalence : 0.8680
##          Detection Rate : 0.8360
##    Detection Prevalence : 0.8540
##       Balanced Accuracy : 0.9134
##
##        'Positive' Class : 0
##
```

Árvore de Decisão

```
print(confusao_ad)
```

```
## Confusion Matrix and Statistics
##
##    previsoes
##       0   1
##   0 420   7
##   1  11  62
##
##                Accuracy : 0.964
##                  95% CI : (0.9437, 0.9785)
##     No Information Rate : 0.862
##     P-Value [Acc > NIR] : 1.534e-14
##
##                   Kappa : 0.8523
##  Mcnemar's Test P-Value : 0.4795
##
##             Sensitivity : 0.9745
##             Specificity : 0.8986
##          Pos Pred Value : 0.9836
```

```
##          Neg Pred Value : 0.8493
##              Prevalence : 0.8620
##          Detection Rate : 0.8400
##    Detection Prevalence : 0.8540
##       Balanced Accuracy : 0.9365
##
##        'Positive' Class : 0
##
```